

# MAT02035 - Modelos para dados correlacionados

## Estimação e inferência estatística

Rodrigo Citton P. dos Reis  
citton.padilha@ufrgs.br

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL  
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA  
DEPARTAMENTO DE ESTATÍSTICA

Porto Alegre, 2019

# Introdução

# Introdução

- ▶ Até agora, nossa discussão de modelos para dados longitudinais tem sido muito geral, sem menção de métodos para estimar os coeficientes de regressão ou a covariância entre as medidas repetidas.
- ▶ **Relembrando:** o modelo de regressão linear geral para o vetor de resposta média

$$E(Y_i|X_i) = X_i\beta.$$

- ▶ Assumimos que o vetor de respostas,  $Y_i$ , tem uma distribuição condicional que é **normal multivariada** com matriz de covariância

$$\text{Cov}(Y_i|X_i) = \Sigma_i = \Sigma_i(\theta).$$

- ▶ Note que  $\theta$  é um vetor  $q \times 1$  de **parâmetros de covariância**.

# Introdução

- ▶ Dados balanceados ( $n_i = n$ ), em que covariância “não-estruturada” é assumida, temos  $n$  variâncias e  $\frac{n(n-1)}{2}$  covariâncias como elementos do vetor  $\theta$ .
- ▶ Se a covariância é assumida ter um padrão de “simetria composta”, então  $q = 2$  e  $\theta$  tem dois elementos.
- ▶ Nesta aula, consideramos uma estrutura para estimativa dos parâmetros desconhecidos,  $\beta$  e  $\theta$  (ou equivalentemente,  $\Sigma_i$ ).

## Estimação: máxima verossimilhança

# Estimação: máxima verossimilhança

- ▶ Dado que foram feitas suposições completas sobre a distribuição do vetor de respostas,  $Y_i$ , uma abordagem muito geral de estimativa é o **método da máxima verossimilhança (MV)**.
  - ▶ A ideia fundamental por trás da estimativa de MV é realmente bastante simples e é transmitida por seu nome: use como estimativas de  $\beta$  e  $\theta$  os valores que são mais prováveis (ou mais “verossímeis”) para os dados que foram realmente observados.
  - ▶ As estimativas de verossimilhança máxima de  $\beta$  e  $\theta$  são aqueles valores de  $\beta$  e  $\theta$  que maximizam a probabilidade conjunta das variáveis resposta **avaliadas em seus valores observados**.

# Estimação: máxima verossimilhança

- ▶ A probabilidade das variáveis de resposta avaliadas no conjunto fixo de valores observados e consideradas como funções de  $\beta$  e  $\Sigma_i(\theta)$  é conhecida como **função de verossimilhança**.
  - ▶ Assim, a estimativa de  $\beta$  e  $\theta$  prossegue **maximizando** a função de verossimilhança.
- ▶ Os valores de  $\beta$  e  $\theta$  que maximizam a função de verossimilhança são chamados de **estimativas de máxima verossimilhança** de  $\beta$  e  $\theta$ , e geralmente são indicados  $\hat{\beta}$  e  $\hat{\theta}$  (ou  $\hat{\Sigma}_i$ ,  $\Sigma_i(\hat{\theta})$ ).

# Observações independentes

- ▶ Suponha que os dados surjam de uma série de estudos transversais que são repetidos em  $n$  ocasiões diferentes.
- ▶ Em cada ocasião, os dados são obtidos em uma amostra de  $N$  indivíduos.
  - ▶ Aqui é razoável supor que as observações sejam **independentes** umas das outras, uma vez que cada indivíduo é medido em apenas uma ocasião.
- ▶ Além disso, para facilitar a exposição, assumimos que a variância é constante, digamos a  $\sigma^2$ .
- ▶ A resposta média está relacionada às covariáveis através do seguinte modelo de regressão linear:

$$E(Y_{ij}|X_{ij}) = X'_{ij}\beta.$$



# Observações independentes

- ▶ Para obter estimativas de máxima verossimilhança de  $\beta$ , devemos encontrar os valores dos parâmetros de regressão que maximizem a função de densidade de probabilidade normal conjunta de todas as observações, avaliados nos valores observados da resposta e considerados como uma função de  $\beta$  (e  $\sigma^2$ ).
- ▶ **Lembrando** que a função de densidade de probabilidade normal (ou gaussiana) univariada para  $Y_{ij}$ , dado  $X_{ij}$ , pode ser expressa como

$$f(y_{ij}) = (2\pi\sigma^2)^{-1/2} \exp \left\{ -\frac{1}{2}(y_{ij} - \mu_{ij})^2 / \sigma^2 \right\}, \quad -\infty < y_{ij} < \infty.$$

# Observações independentes

- ▶ Quando todas as respostas são independentes umas das outras, a função de verossimilhança é simplesmente o produto das funções individuais de densidade de probabilidade normal univariada para  $Y_{ij}$  dado  $X_{ij}$ ,

$$\prod_{i=1}^N \prod_{j=1}^n f(y_{ij}).$$

## Observações independentes

- ▶ É mais comum trabalhar com a função **log-verossimilhança**, que envolverá somas, em vez de produtos, das funções individuais de densidade de probabilidade normal univariada para  $Y_{ij}$ .
  - ▶ Observe que maximizar a verossimilhança é equivalente a maximizar o logaritmo da verossimilhança; o último é indicado por  $l$ .
- ▶ Portanto, o objetivo é maximizar

$$l = \log \left\{ \prod_{i=1}^N \prod_{j=1}^n f(y_{ij}) \right\} = -\frac{K}{2} \log(2\pi\sigma^2) - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^n (y_{ij} - X'_{ij}\beta)^2 / \sigma^2,$$

avaliado nos valores numéricos observados dos dados, em relação aos parâmetros de regressão,  $\beta$ . - Aqui  $K = n \times N$ , o **número total de observações**.

# Observações independentes

- ▶ Observe que  $\beta$  não aparece no primeiro termo da log-verossimilhança.
  - ▶ Como resultado, esse termo pode ser ignorado ao maximizar a log-verossimilhança em relação a  $\beta$ .
- ▶ Além disso, como o segundo termo tem um sinal negativo, maximizar a log-verossimilhança em relação a  $\beta$  é equivalente a minimizar a seguinte função:

$$\sum_{i=1}^N \sum_{j=1}^n (y_{ij} - X'_{ij}\beta)^2.$$

# Observações independentes

- ▶ Maximizar ou minimizar uma função é um problema matemático comum que pode ser resolvido usando o cálculo.
- ▶ Especificamente, a estimativa de máxima verossimilhança de  $\beta$  pode ser obtida igualando a derivada da log-verossimilhança, frequentemente chamada de **função score**, a zero e encontrando a solução para a equação resultante.
- ▶ No entanto, no exemplo considerado aqui, não há necessidade real de recorrer ao cálculo.
- ▶ A obtenção da estimativa de máxima verossimilhança de  $\beta$  é equivalente a encontrar a estimativa de **mínimos quadrados ordinários** (MQO) de  $\beta$ , ou seja, o valor de  $\beta$  que minimiza a soma dos quadrados dos resíduos.

# Observações independentes

- ▶ Usando a notação vetorial, a solução dos mínimos quadrados pode ser escrita como

$$\hat{\beta} = \left\{ \sum_{i=1}^N \sum_{j=1}^n (X_{ij} X'_{ij}) \right\}^{-1} \sum_{i=1}^N \sum_{j=1}^n (X_{ij} y_{ij}).$$

- ▶ Essa estimativa de mínimos quadrados é o valor produzido por qualquer *software* estatístico padrão para regressão linear (por exemplo, PROC GLM ou PROC REG no SAS, a função `lm` no R e o comando `regress` no Stata).
  - ▶ **Exercício:** considere o modelo dos dados de nível de chumbo no sangue; compare as estimativas através de uma implementação sua de  $\hat{\beta}$  com a função `lm`.
- ▶ Além disso, note que até agora apenas focamos na estimativa de  $\beta$ , ignorando a estimativa de  $\sigma^2$ ; a seguir, também consideramos a estimativa da matriz de covariância.

# Observações correlacionadas

- ▶ Quando há  $n_i$  medidas repetidas no mesmo indivíduo, **não se pode assumir que essas medidas repetidas são independentes**.
  - ▶ Como resultado, precisamos considerar a função de densidade de probabilidade conjunta para o **vetor de medidas repetidas**.
- ▶ Observe, no entanto, que os vetores de medidas repetidas são assumidos como **independentes** uns dos outros.
  - ▶ Assim, a função log-verossimilhança,  $l$ , pode ser expressa como uma **soma das funções multivariadas individuais** da densidade de probabilidade normal para  $Y_i$  dado  $X_i$ .

# Observações correlacionadas

- ▶ Primeiro assumimos que  $\Sigma_i$  (ou  $\theta$ ) é conhecido (e, portanto, não precisa ser estimado); depois, relaxaremos essa suposição muito irrealista.
- ▶ Dado que  $Y_i = (Y_{i1}, Y_{i2}, \dots, Y_{in_i})'$  é assumido como tendo uma distribuição condicional que é normal multivariada, devemos maximizar a seguinte função de log-verossimilhança:

$$l = -\frac{K}{2} \log(2\pi) - \frac{1}{2} \sum_{i=1}^N \log |\Sigma_i| - \frac{1}{2} \left\{ \sum_{i=1}^N (y_i - X_i \beta)' \Sigma_i^{-1} (y_i - X_i \beta) \right\},$$

- ▶  $K = \sum_{i=1}^N n_i$  é o **número total de observações**.



# Observações correlacionadas

- ▶ Note que  $\beta$  não aparece nos dois primeiros termos na log-verossimilhança.
  - ▶ Esses dois termos podem ser ignorados ao maximizar a log-verossimilhança em relação a  $\beta$ .
- ▶ Além disso, como o terceiro termo tem um sinal negativo, maximizar a log-verossimilhança em relação a  $\beta$  é equivalente a minimizar

$$\sum_{i=1}^N (y_i - X_i\beta)' \Sigma_i^{-1} (y_i - X_i\beta).$$

# Observações correlacionadas

- ▶ O estimador de  $\beta$  que minimiza essa expressão é conhecido como estimador de **mínimos quadrados generalizados** (MQG) de  $\beta$  e pode ser expresso como

$$\hat{\beta} = \left\{ \sum_{i=1}^N (X_i' \Sigma_i^{-1} X_i) \right\}^{-1} \sum_{i=1}^N (X_i' \Sigma_i^{-1} y_i).$$

- ▶ Veja a função `gls` do pacote `nlme` do R.

## Propriedades do estimador MQG ( $\Sigma_i$ conhecida)

- ▶ A primeira propriedade muito notável é que, para **qualquer** escolha de  $\Sigma_i$ , a estimativa MQG de  $\beta$  é **não viesada**. Ou seja,

$$E[\hat{\beta}] = \beta.$$

- ▶ Além disso, **em amostras grandes** (ou assintoticamente), pode se mostrar que a distribuição amostral de  $\hat{\beta}$  é uma distribuição normal multivariada com média  $\beta$  e covariância

$$\text{Cov}(\hat{\beta}) = \left\{ \sum_{i=1}^N (X_i' \Sigma_i^{-1} X_i) \right\}^{-1}.$$

## Propriedades do estimador MQG ( $\Sigma_i$ conhecida)

- ▶ Isso é verdade exatamente quando  $Y_i$  tem uma distribuição condicional que é multivariada normal e verdadeira em **amostras grandes**, mesmo quando a distribuição condicional de  $Y_i$  não é normal multivariada.
  - ▶ Por “grandes amostras”, entendemos que o tamanho da amostra,  $N$ , aumenta quando o número de medidas repetidas e parâmetros do modelo permanece fixo.
- ▶ Observe também que se  $\Sigma_i$  for assumido como uma matriz diagonal, com variância constante  $\sigma^2$  ao longo da diagonal, o estimador MQG reduz para o estimador de mínimos quadrados ordinários considerado mais cedo.
  - ▶ **Exercício:** demonstre este resultado.
- ▶ Finalmente, embora o estimador MQG de  $\beta$  seja não viesado para qualquer escolha de  $\Sigma_i$ , pode ser mostrado que o estimador MQG mais eficiente de  $\beta$  (ou seja, o estimador com menor variância ou maior precisão) é aquele que usa o valor verdadeiro de  $\Sigma_i$ .
  - ▶ **Pergunta:** o que isto quer dizer?

## MQG ( $\Sigma_i$ desconhecida)

- ▶ Vamos abordar o caso que geralmente ocorre na prática: não conhecemos  $\Sigma_i$  (ou  $\theta$ ).
  - ▶ Neste caso precisamos estimar  $\Sigma_i$  ( $\theta$ ) a partir dos dados disponíveis.
- ▶ A estimativa da máxima verossimilhança de  $\theta$  prossegue da mesma maneira que a estimativa de  $\beta$ , maximizando a log-verossimilhança em relação a  $\theta$ .
- ▶ Especificamente, a estimativa de máxima verossimilhança de  $\theta$  pode ser obtida igualando a derivada da log-verossimilhança em relação a  $\theta$  (função escore) a zero e encontrando a solução para a equação resultante.
- ▶ Entretanto, em geral, essa **equação é não linear** e não é possível escrever expressões simples e de forma fechada para o estimador de MV de  $\theta$ .
  - ▶ A estimativa de MV deve ser encontrada resolvendo-se essa equação usando uma técnica **iterativa**.

## MQG ( $\Sigma_i$ desconhecida)

- ▶ Felizmente, algoritmos de computador foram desenvolvidos para encontrar a solução.
- ▶ Uma vez obtida a estimativa de MV de  $\theta$ , simplesmente substituímos a estimativa de  $\Sigma_i(\theta)$ , digamos  $\hat{\Sigma}_i = \Sigma_i(\hat{\theta})$ , no estimador de mínimos quadrados generalizados de  $\beta$  para obter a estimativa de MV de  $\beta$ :

$$\hat{\beta} = \left\{ \sum_{i=1}^N (X_i' \hat{\Sigma}_i^{-1} X_i) \right\}^{-1} \sum_{i=1}^N (X_i' \hat{\Sigma}_i^{-1} y_i).$$

## Propriedades do estimador MQG ( $\Sigma_i$ conhecida)

- ▶ Curiosamente, **em amostras grandes** (ou assintoticamente), o estimador resultante de  $\beta$  que substitui a estimativa de MV de  $\Sigma_i$  tem todas as **mesmas propriedades** de quando  $\Sigma_i$  é realmente conhecido.
- ▶ Assim, em termos de propriedades da distribuição amostral de  $\hat{\beta}$ , não há penalidade por realmente ter que estimar  $\Sigma_i$  a partir dos dados longitudinais em questão.
- ▶ No entanto, por mais reconfortante que esse resultado possa parecer, deve-se ter em mente que esta é uma propriedade de grande amostra (ou seja, quando  $N$  se aproxima do infinito) de  $\hat{\beta}$ .
  - ▶ Com tamanhos de amostra da magnitude frequentemente encontrados em muitas áreas de aplicação, pode-se esperar que as propriedades da distribuição amostral de  $\hat{\beta}$  sejam adversamente influenciadas pela estimativa de um número muito grande de parâmetros de covariância.

# Questões de dados ausentes



# Questões de dados ausentes

Embora a maioria dos estudos longitudinais seja projetada para coletar dados de cada indivíduo da amostra a cada momento do acompanhamento, muitos estudos têm algumas observações ausentes.

Dados ausentes têm três implicações importantes para a análise longitudinal:

1. O conjunto de dados é necessariamente desbalanceado ao longo do tempo, pois nem todos os indivíduos têm o mesmo número de medições repetidas em um conjunto comum de ocasiões.
  - ▶ Como resultado, os métodos de análise precisam ser capazes de lidar com os dados desequilibrados sem precisar descartar dados de indivíduos com dados ausentes.

# Questões de dados ausentes

2. Haverá perda de informações e redução na precisão com que mudanças na resposta média ao longo do tempo pode ser estimado.
  - ▶ Essa redução na precisão está diretamente relacionada à quantidade de dados ausentes e também será influenciada em certa medida pela maneira como a análise lida com os dados ausentes.
  - ▶ Por exemplo, usar apenas os casos completos (ou seja, aqueles indivíduos sem dados ausentes) geralmente será o método menos eficiente.
3. A validade de qualquer método de análise exigirá que certas suposições sobre os motivos de qualquer falta, geralmente chamadas de **mecanismo de perda de dados**, sejam sustentáveis.
  - ▶ Consequentemente, quando faltam dados, devemos considerar cuidadosamente os motivos da falta.

# Mecanismo de perda de dados

- ▶ O mecanismo de perda de dados pode ser pensado como **um modelo** que descreve a probabilidade de uma resposta ser observada ou ausente em qualquer ocasião.
- ▶ Fazemos uma distinção importante entre mecanismos de dados ausentes que são referidos como **ausentes completamente ao acaso** (*missing completely at random* - MCAR) e **ausentes ao acaso** (*missing at random* - MAR).
- ▶ A distinção entre esses dois mecanismos determina a adequação da estimativa de máxima verossimilhança sob o pressuposto de uma distribuição normal multivariada para as respostas e o MQG sem exigir suposições sobre o formato da distribuição.

# MCAR

- ▶ Diz-se que os dados são MCAR quando a probabilidade de perda de respostas não está relacionada aos valores específicos que, em princípio, deveriam ter sido obtidos (as respostas ausentes) ou ao conjunto de respostas observadas.
- ▶ Ou seja, dados longitudinais são MCAR quando a falta em  $Y_i$  é simplesmente o resultado de um mecanismo de chance que não depende de componentes observados ou não observados de  $Y_i$ .
- ▶ A característica essencial do MCAR é que os dados observados podem ser considerados uma amostra aleatória dos dados completos.
  - ▶ Como resultado, os momentos (por exemplo, médias, variâncias e covariâncias) e, de fato, a distribuição dos dados observados não diferem dos momentos correspondentes ou da distribuição dos dados completos.

# MCAR

- ▶ Qualquer método de análise que produza inferências válidas na ausência de dados ausentes também produzirá inferências válidas quando os dados ausentes forem MCAR e a análise for baseada em todos os dados disponíveis, ou mesmo quando estiver restrito aos “completadores” (ou seja, aqueles sem dados ausentes).
- ▶ Dado que estimativas válidas das médias, variâncias e covariâncias podem ser obtidas, o MQG fornece estimativas válidas de  $\beta$  sem exigir nenhuma premissa de distribuição para  $Y_i$ .
- ▶ O estimador MQG de  $\beta$  é válido, desde que o modelo para a resposta média tenha sido especificado corretamente; não requer nenhuma suposição sobre a distribuição conjunta das respostas longitudinais.

# MCAR

- ▶ O estimador de MV de  $\beta$ , pressupondo que as respostas tenham uma distribuição normal multivariada, também é o estimador MQG (com a estimativa MV de  $\Sigma_i(\theta)$ , por exemplo,  $\hat{\Sigma}_i = \Sigma_i(\hat{\theta})$ , substituída).
- ▶ Assim, nessa configuração, os estimadores MV e MQG têm exatamente as mesmas propriedades, independentemente da verdadeira distribuição de  $Y_i$ .

# MAR

- ▶ Ao contrário do MCAR, diz-se que os dados são MAR quando a probabilidade de perda de respostas depende do conjunto de respostas observadas, mas não está relacionada aos valores ausentes específicos que, em princípio, deveriam ter sido obtidos.
- ▶ Em outras palavras, se os indivíduos são estratificados com base em valores semelhantes para as respostas observadas, a falta é simplesmente o resultado de um mecanismo de chance que não depende dos valores das respostas não observadas.
- ▶ No entanto, como o mecanismo de falta agora depende das respostas observadas, a distribuição de  $Y_i$  em cada um dos estratos distintos definidos pelos padrões de falta não é o mesmo que a distribuição de  $Y_i$  na população alvo.
- ▶ Isso tem consequências importantes para a análise.

## MAR

- ▶ Uma é que uma análise restrita aos “completadores” não é válida.
  - ▶ Em outras palavras, os “completadores” são uma amostra tendenciosa da população-alvo.
- ▶ Além disso, a distribuição dos componentes observados de  $Y_i$ , em cada um dos estratos distintos definidos pelos padrões de falta, não coincide com a distribuição dos mesmos componentes de  $Y_i$  na população alvo.
  - ▶ Portanto, as médias amostrais, variâncias e covariâncias com base nos “completadores” ou nos dados disponíveis são estimativas tendenciosas dos parâmetros correspondentes na população-alvo.



# MAR

- ▶ Como resultado, o MQG não fornece mais estimativas válidas de  $\beta$  sem fazer suposições corretas sobre a distribuição conjunta das respostas longitudinais.
- ▶ Por outro lado, a estimativa de MV de  $\beta$  é válida quando os dados são MAR, desde que a distribuição normal multivariada foi especificada corretamente.
  - ▶ Isso requer a especificação correta não apenas do modelo para a resposta média, mas também do modelo para a covariância entre as respostas.
- ▶ Em certo sentido, a estimativa de MV permite que os valores ausentes sejam validamente “previstos” ou “imputados” usando os dados observados e um modelo correto para a distribuição conjunta das respostas.

# Inferência estatística

# Inferência estatística

- ▶ Para construir **intervalos de confiança** e **testes de hipóteses** sobre  $\beta$ , podemos fazer uso direto das estimativas de MV  $\hat{\beta}$  e da sua matriz de covariância estimada

$$\widehat{\text{Cov}}(\hat{\beta}) = \left\{ \sum_{i=1}^N (X_i' \hat{\Sigma}_i^{-1} X_i) \right\}^{-1}.$$

# Inferência estatística

- ▶ Para um único componente de  $\beta$ , digamos  $\beta_k$ , um método natural de construção de **limites de confiança** de 95% é tomar o  $\hat{\beta}_k$  mais ou menos 1,96 vezes o erro padrão de  $\hat{\beta}_k$ .
  - ▶ Diferentes limites de confiança podem ser obtidos escolhendo os quantis apropriados da distribuição normal padrão.
- ▶ O erro padrão de  $\hat{\beta}_k$  é simplesmente a raiz quadrada do elemento da diagonal principal de  $\widehat{\text{Cov}}(\hat{\beta})$  correspondente a  $\hat{\beta}_k$ ,

$$\sqrt{\widehat{\text{Var}}(\hat{\beta}_k)}.$$

# Inferência estatística

- ▶ De maneira similar, um **teste da hipótese** nula,  $H_0 : \beta_k = 0$  versus  $H_A : \beta_k \neq 0$ , pode ser baseado na seguinte estatística de Wald:

$$Z = \frac{\hat{\beta}_k}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_k)}},$$

em que  $\widehat{\text{Var}}(\hat{\beta}_k)$  denota o elemento da diagonal principal de  $\widehat{\text{Cov}}(\hat{\beta})$  correspondente a  $\hat{\beta}_k$ .

- ▶ Esta estatística de teste pode ser comparada com uma distribuição normal padrão.

# Inferência estatística

- ▶ De maneira mais geral, pode ser de interesse construir intervalos de confiança e testes de hipóteses com respeito a certas **combinações lineares** dos componentes de  $\beta$ .
- ▶ Seja  $L$  um vetor ou uma matriz de pesos **conhecidos** e suponha que é de interesse testar  $H_0 : L\beta = 0$ .
- ▶ A combinação linear dos componentes de  $\beta$ ,  $L\beta$ , representa um **contraste** de interesse científico.
  - ▶ Exemplo: suponha que  $\beta = (\beta_1, \beta_2, \beta_3)'$  e  $L = (0, 0, 1)$ , então  $H_0 : L\beta = 0$  é equivalente a  $H_0 : \beta_3 = 0$ .
    - ▶ Agora, se considerarmos  $L = (0, 1, -1)$ , então  $H_0 : L\beta = 0$  é equivalente a  $H_0 : \beta_2 - \beta_3 = 0$  ou  $H_0 : \beta_2 = \beta_3$ .

# Inferência estatística

- ▶ Uma estimativa natural de  $L\beta$  é  $L\hat{\beta}$ , e pode ser mostrado que  $L\hat{\beta}$  tem distribuição normal multivariada com média  $L\beta$  e matriz de covariância  $LCov(\hat{\beta})L'$ .
- ▶ Nos dois exemplos anteriores,  $L$  é um único vetor linha  $1 \times 3$ ,  $L = (0, 0, 1)$  ou  $L = (0, 1, -1)$ .
- ▶ Se  $L$  é um único vetor linha, então  $LCov(\hat{\beta})L'$  é um único valor (escalar) e a sua raiz quadrada fornece uma estimativa do erro padrão para  $L\hat{\beta}$ .
- ▶ Assim um intervalo de confiança de aproximadamente 95% para  $L\beta$  é dado por

$$L\hat{\beta} \pm 1,96\sqrt{\widehat{LCov}(\hat{\beta})L'}.$$

# Inferência estatística

- ▶ De forma similar, para testar  $H_0 : L\beta = 0$  versus  $H_A : L\beta \neq 0$ , podemos usar a estatística de Wald

$$Z = \frac{L\hat{\beta}}{\sqrt{L\widehat{\text{Cov}}(\hat{\beta})L'}},$$

e comparar esta estatística de teste com a distribuição normal padrão.

- ▶ Um teste idêntico para  $H_0 : L\beta = 0$  versus  $H_A : L\beta \neq 0$  usa a estatística

$$W^2 = (L\hat{\beta})\{L\widehat{\text{Cov}}(\hat{\beta})L'\}^{-1}(L\hat{\beta}),$$

e comparar  $W^2$  com a distribuição  $\chi^2$  com 1 grau de liberdade (**por que?**).



# Inferência estatística

- ▶ Esta última observação nos ajuda a motivar como o teste de Wald prontamente generaliza quando  $L$  tem mais que uma linha, permitindo o teste simultâneo de uma hipótese multivariada.
- ▶ Por exemplo, suponha que  $\beta = (\beta_1, \beta_2, \beta_3)'$  e é de interesse testar a igualdade dos três parâmetros de regressão.
  - ▶ A hipótese nula pode ser expressa como  $H_0 : \beta_1 = \beta_2 = \beta_3$ . Fazendo

$$L = \begin{pmatrix} 1 & -1 & 0 \\ 1 & 0 & -1 \end{pmatrix}.$$

# Inferência estatística

- $H_0 : \beta_1 = \beta_2 = \beta_3$  pode ser expressa como  $H_0 : L\beta = 0$ , pois se

$$\begin{aligned} L\beta &= \begin{pmatrix} 1 & -1 & 0 \\ 1 & 0 & -1 \end{pmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} \\ &= \begin{pmatrix} \beta_1 - \beta_2 \\ \beta_1 - \beta_3 \end{pmatrix} = 0, \end{aligned}$$

e então

$$\begin{pmatrix} \beta_1 \\ \beta_1 \end{pmatrix} = \begin{pmatrix} \beta_2 \\ \beta_3 \end{pmatrix}.$$

# Inferência estatística

- ▶ Em geral, suponha que  $L$  tem  $r$  linhas (representando  $r$  contrastes de interesse científico), então um teste simultâneo de  $H_0 : L\beta = 0$  versus  $H_A : L\beta \neq 0$  é dado por

$$W^2 = (L\hat{\beta})' \{L\widehat{\text{Cov}}(\hat{\beta})L'\}^{-1}(L\hat{\beta}),$$

que tem uma distribuição  $\chi^2$  com  $r$  gl.

- ▶ Este é o teste de Wald multivariado.

# Inferência estatística

- ▶ Uma alternativa para o teste de Wald é o **teste da razão de verossimilhanças**.
- ▶ O teste da razão de verossimilhanças de  $H_0 : L\beta = 0$  versus  $H_A : L\beta \neq 0$  é obtido comparando as log-verossimilhanças maximizada para dois modelos:
  - ▶ um modelo incorpora a restrição que  $L\beta = 0$  (por exemplo,  $\beta_3 = 0$  ou  $\beta_2 = \beta_3$ ); este será chamado de **modelo reduzido**;
  - ▶ e outro modelo sem restrição; este será chamado de **modelo completo**.

# Inferência estatística

- ▶ Uma estatística de teste é obtida por

$$G^2 = 2(\hat{l}_{\text{comp}} - \hat{l}_{\text{red}}),$$

e comparamos esta estatística com uma distribuição qui-quadrado com graus de liberdade igual a diferença entre o número de parâmetros nos modelos completo e reduzido.

- ▶ **Observação:** o teste da razão de verossimilhança só pode ser usado quando o número de observações para os modelos completo e reduzido for o mesmo; **atenção com dados ausentes nas covariáveis.**

# Inferência estatística

- ▶ O uso da verossimilhança também pode fornecer limites de confiança para  $\beta$  ou  $L\beta$ .
- ▶ Para um único componente de  $\beta$ , digamos  $\beta_k$ , podemos definir uma função **log-verossimilhança perfilada**,  $l_p(\beta_k)$ , obtida maximizando a log-verossimilhança sobre os parâmetros restantes, mantendo  $\beta_k$  em algum valor fixo.

# Inferência estatística

- ▶ Um intervalo de confiança baseado na verossimilhança para  $\beta_k$  é obtido considerando-se valores de  $\beta_k$  que são razoavelmente consistentes com os dados.
  - ▶ Especificamente, um intervalo de confiança aproximado de 95% baseado na verossimilhança é dado pelo conjunto de todos os valores de  $\beta_k$  que satisfazem

$$2 \times \{l_p(\hat{\beta}_k) - l_p(\beta_k)\} \leq 3,84,$$

em que o valor crítico 3,84 é obtido da distribuição qui-quadrado com 1 grau de liberdade.

- ▶ De maneira mais geral, os intervalos de confiança para  $L\beta$  podem ser obtidos invertendo o teste correspondente de  $H_0 : L\beta = 0$  de maneira semelhante.

# Comentários

- ▶ Embora a construção de testes de razão de verossimilhança e intervalos de confiança com base em verossimilhança seja mais enredada (por exemplo, exigindo um ajuste adicional do modelo sob a hipótese nula) do que os correspondentes testes e intervalos de confiança com base na estatística de Wald, os testes e intervalos de confiança baseados em verossimilhança geralmente têm **propriedades superiores**.
- ▶ Este é especialmente o caso quando a variável de resposta é discreta.
  - ▶ Por exemplo, na regressão logística com dados binários, os testes de razão de verossimilhança têm melhores propriedades que os testes de Wald correspondentes.
- ▶ Portanto, em caso de dúvida, recomenda-se o uso de testes e intervalos de confiança baseados em verossimilhança.



## Comentários

- ▶ Notamos que testes de razão de verossimilhança também podem ser usados para hipóteses sobre os **parâmetros de covariância**.
- ▶ No entanto, existem alguns problemas em potencial com o uso padrão do teste da razão de verossimilhança para comparar modelos aninhados para a covariância; retornaremos a este tópico quando discutirmos a modelagem da estrutura de covariância.
- ▶ Em geral, não é recomendado testar hipóteses sobre os parâmetros de covariância usando testes de Wald.
  - ▶ Em particular, a distribuição amostral da estatística do teste Wald para um parâmetro de variância não possui uma distribuição normal aproximada quando o tamanho da amostra é relativamente pequeno e a variância populacional é próxima de zero.
  - ▶ Como a variância tem um limite inferior igual a zero, são necessárias amostras muito grandes para justificar a aproximação normal para a distribuição amostral da estatística do teste de Wald quando a variância está próxima de zero.

# Exercícios

# Exercícios

1. (Re)fazer as provas dos resultados discutidos na aula de hoje.
2. Utilize os dados do estudo dos níveis de chumbo no sangue (TLC).
  - ▶ Proponha um modelo de regressão linear para a média com base nas questões de pesquisa.
  - ▶ Encontre as estimativas para os coeficientes de regressão do modelo proposto (use a função `glm` do pacote `nlme` do R; explore diferentes especificações da covariância - veja a documentação de `corClasses`).
  - ▶ **Com base nas estimativas**, faça a exposição das suas conclusões.

# Avisos

- ▶ **Próxima semana:** lista de exercícios nº 1.
  - ▶ O momento da aula será utilizado para a resolução dos exercícios da lista.
- ▶ **Para casa:** ler o Capítulo 4 do livro “**Applied Longitudinal Analysis**”.
  - ▶ Fazer um resumo da Seção 4.5.
  - ▶ Caso ainda não tenha lido, leia também os Caps. 1, 2 e 3.
  - ▶ Ver também as referências com respeito à derivadas de vetores, matrizes, etc.
- ▶ **Próxima aula (1º/10):** Modelando a média através da análise de perfis de respostas.

Bons estudos!

